智能眼镜自适应沟通辅助研究 实施附件

申请人：Zhiheng Zhang

版本：CSG-PROPOSAL-20261022-v2

日期：2026-10-22

本附件供与李雪亮博士讨论实施方案，可独立阅读。研究为 PROPOSED，原型为 PLANNED，实机及参与者研究为 NOT_RUN。仅第 6 节合成设计计算已经运行，不代表伦理批准、产品有效或样本量充足。

目录

1 研究对象 招募与执行流程.....3

2 十八段材料 条件分配与完整评分示例.....4

3 六个恢复探针与曝光记录.....7

4 问卷 访谈 同意与数据字段.....8

5 主要统计模型 区间与缺失规则.....10

6 已运行的设计精度模拟.....12

7 非阻塞算法 数据契约与原始权限.....14

8 平台操作步骤及未测试证据表.....15

9 首年工作包 工时与资源预算.....17

10 启动冻结清单与交付判定.....18

1 研究对象 招募与执行流程

入组与研究关系

核心研究面向年满 18 岁、自我认同为聋人或重听者（DHH）、愿意在口语任务中使用书面字幕的成人。先确定主要研究语言和沟通支持。默认不要求听力图、诊断或健康史，不以熟悉人工智能为资格。设计关注字幕经验、偏好和伙伴关系，不只追求转写指标 [1], [2]。

经机构批准的社区或公开渠道招募。私密筛选询问年龄、字幕意愿、语言、沟通支持、佩戴调整、休息及材料暴露。联系方式与答案分开；不按能力挑选实验顺序，不利用师生或雇佣关系施压，不在公开仓库收集报名和健康资料。

说明用语：“我们想知道额外提示何时帮助、何时打扰。你可以只用字幕或拒绝提示。设备会出错，这不是社交能力评判或医疗工具。”合理调整仍不能满足的需要记为设计限制，不归咎于参与者。

阶段与人数

阶段	规划参与及活动	进入下一阶段的证据
技术与伦理准备	使用合成或获准材料，不采集未批准研究数据	合法平台路线、可访问说明、数据和停止流程
形成性共创	6–8 名 DHH 成人；情境访谈与 2–3 种低保真布局	词表、布局、未知状态、退出方式和分歧记录
试运行	4–6 人，检查材料、负担、测量与日志	修订理由、精度规划和主研究冻结版本
主研究	暂定随机分配 24 人；被试内比较三条件	按冻结计划执行、报告缺失与偏离
可选现场扩展	主研究中 6–8 人及另行同意的伙伴	真实输入、舒适度、隐私与设备验证通过

24 是随机分配目标，不事后补足完整或高表现完成者；36、48 人仅用于资源与精度讨论。试点参与者不纳入正式主实验分析。共创者若再参加，须预先明确资格、材料暴露和记录方式。HR／EMG 探索独立立项。

单次主研究流程

环节	时间起点	实际执行规则
说明、同意、佩戴与练习	约 15 分钟	确认理解、停止入口和通常沟通支持；练习不计分
三个条件区块	每区块约 12–15 分钟	各六段对话、每段两题，区块末填写六项体验题

环节	时间起点	实际执行规则
区块间休息	两次各至少约 5 分钟	可增加，不因延长休息记为错误
六探针、访谈及结束说明	约 10–15 分钟	与主要任务分开，先处理不适，再进行自愿讨论

先按 80–90 分钟预约，待试运行校准，不强制限时。可拆两场，保留顺序、暴露和间隔记录，另计出行及沟通支持。共创、试运行各按 75–90 分钟，现场扩展另按 45–60 分钟。

同意、访问支持和练习完成后，首段主要材料前随机分配。允许暂停、仅字幕、跳题及退出；关闭不静默重开。切换条件需恢复设置时由本人明确操作。采集前冻结材料、答案、候选池、策略、分配、分析及停止规则；公开草案不等于预注册。

2 十八段材料 条件分配与完整评分示例

材料规模与题型

制作 18 段 45–60 秒的两至三人低风险对话，每段两题，共 36 题。A、B、C 三集合各六段、12 题，各含三段两人和三段三人对话。T1 检查强调与对比后的事实整合，T2 检查明确沟通功能与下一步，T3 检查重叠或修正后的最终版本；每集合每类题各四道。

槽位（各集合对应）	人数与题型	低风险制作主题
A01／B01／C01	两人；T1＋T2	展板、读书会或工作坊的时间地点
A02／B02／C02	三人；T1＋T3	物品清单、存放位置及修订
A03／B03／C03	两人；T2＋T3	设备借用与尚待确认事项
A04／B04／C04	三人；T1＋T2	活动角色与行动顺序
A05／B05／C05	两人；T1＋T3	文件版本与发送对象
A06／B06／C06	三人；T2＋T3	流程、地点变更和最终安排

每题整合至少两个话轮，答案依据完整录音、脚本与独立标注，不反推模型输出。集合匹配长度、事实数、题型和输入难度，不重复故事答案。能抄提示作答的题重写；实质歧义题移出主要题集。

至少两名标注者不看模型判断，独立给答案和理由后讨论分歧。材料卡存题号、对话号、集合、题型、相关话轮、答案、干扰项理由及许可。试点按 C0 可答性、地板／天花板和负担修改，不挑 C2–C0 最大的题；4–6 人不足以稳定估计单题难度。

三条件及六行平衡块

C0 仅字幕。C1 为基础调度辅助：在共同有效性、容量与调度约束下呈现候选，不增加选择性不确定性或显示负担过滤。C2 在同一候选池上增加冻结的选择性策略。共同规则包括单槽容量、队列、冲突、替换、去重、TTL、未知归属、用户关闭和设备错误；C1 不承诺所有候选都实际可见，也不作为故意拥挤的弱对照。

每人看三个不同集合，同一段不重复。六行基本分配如下；执行程序先重复所需块数，再按固定种子打乱分配槽位。

基本行	三时期的条件顺序	对应材料集合顺序
1	C0 → C1 → C2	A → B → C
2	C1 → C2 → C0	C → A → B
3	C2 → C0 → C1	B → C → A
4	C0 → C2 → C1	A → C → B
5	C1 → C0 → C2	C → B → A
6	C2 → C1 → C0	B → A → C

重复四块得到 24 人：六种条件顺序各四人，条件×集合及集合×时期组合各八人。这是二因素边际平衡，不是条件×时期×集合完整三因素交叉。集合内顺序预先打散，同段两题成组。36／48 人对应六／八块，不自动扩大授权。planned 编号为空槽；参与者无法完全遮蔽，评分清理可先用中性代码。

呈现与字幕控制

前方单屏同框播放两至三名发言人，眼镜使用屏幕相对字幕和匿名角色标识，不是现实人物的世界锁定字幕。坐距、画面、字号位置和个人初始设置试点后固定。保留通常沟通支持，音量舒适且跨条件一致。段末在伴随界面作答，可代录回读，不覆盖播放中的字幕。

录制后用同一 ASR 版本生成增量 trace。三条件共享文本、修订、时间、映射及基础故障，人工参考仅作核查。关键事实严重缺失时，采集前统一重录、重跑或替换整段并记原因；非关键错误可登记保留。结论限于可用字幕基础上的受控回放，不外推任意噪声环境 [3], [4]。

完整链示例 工作坊准备

以下为拟录约 58 秒的合成示例，不是已经录制、运行 ASR 或测得性能的材料。目标时间须经自然试读校准。声音标记只供导演和标注，不自动成为给参与者看的解释。

目标时间	发言人与完整脚本	可核查事实
0–7 秒	甲：我把工作坊安排写成周四下午、大会议室。你们看过这张旧表吗?	引出旧版本
7–14 秒	乙：看过。要改的是日期，改到周五下午；房间按昨晚确认的那一间。	“周五下午”重读；新房间需下一话轮
14–20 秒	丙：我查过，昨晚定的二楼小会议室可以用。我周五上午先把桌牌送过去，可以吗?	明确房间并请求确认
20–27 秒	甲：上午送可以。材料分工呢？我能带纸张，但是胶带昨天没买到。	接受送物安排，说明分工缺口
27–34 秒	乙：胶带我来带。投影仪还没有借到，我需要问一下管理员。	投影仪仍待确认
31–34 秒，与乙重叠	丙：那要不要取消投影?	发生重叠，不证明争执
34–41 秒	乙：这件事的结果，我会在午饭前发给你们。到时候请留意小组消息。	对象须结合前文；承诺不等于已借到
41–49 秒	甲：好。我带纸张，丙送桌牌，乙带胶带并确认投影仪。我按这个分工准备。	汇总分工
49–58 秒	丙：我按新的活动时间和刚确认的房间准备。投影仪有结果再告诉我。乙：对，借不到我们再一起改展示方式。	不在总结句重复整组答案

为解释自然错误处理，可在示意 trace 中假设两次“桌牌”均显示为“桌排”，其他文字不变；三条件同样保留，人工参考仍写桌牌。正式实验必须用实际识别输出替换这一拟制 trace，不能把它当成 ASR 性能样本。

同一固定候选与证据	C0／C1 的处理	C2 的示例处理
E1：乙 7–14 秒重读；标签“强调”	C0 不显示；C1 在共同调度允许后显示	通过冻结判据、显示预算允许时显示
E2：丙 14–20 秒；候选“可能在请求确认”，任务分数未达额外判据	C0 不显示；C1 未触发硬无效规则时按基础调度显示	因不确定性弃权，不能改写成“没有请求”

同一固定候选与证据	C0／C1 的处理	C2 的示例处理
E3：31–34 秒重叠；标签“重叠发言”	C0 不显示；C1 按共同调度显示	若字幕占用／更新代理达到额外门槛，抑制或在原有效期内延后

本示例假设自愿开启辅助且三事件不竞争同一槽位，不附虚构正确概率。正式候选池须冻结每个决定和时间，不能保留示例中的“若”。额外分数门槛与共同硬有效性不是同一回事。

主要题	反应选项	答案与评分
Q1：大家目前应按哪一组活动时间和地点准备？	A 周四下午、二楼小会议室；B 周五下午、二楼小会议室；C 周五下午、大会议室；另有不知道／跳过	B=1；A、C、不知道=0；跳过=缺失。乙给日期、丙给房间，单看一维仍有两个选项
Q2：关于尚待确认的事，应按哪组对象与反馈时间理解乙的承诺？	A 乙确认投影仪能否借到，今天下班前反馈；B 乙确认胶带是否备好，午饭前反馈；C 乙确认投影仪能否借到，午饭前反馈；另有不知道／跳过	C=1；A、B、不知道=0；跳过=缺失。结合未借到与“这件事”的时间承诺，单看一维仍有两个选项

实质选项位置预先打散平衡，同题跨条件相同。组合题整体评分，不事后加部分分。主任务不逐题反馈；反应时仅探索、暂停另记。约 60 秒提供继续、跳过或休息，不自动判错。重播按统一访问规则，不依据答案决定。

3 六个恢复探针与曝光记录

主要任务后安排六个独立片段：两个正确候选、两个可恢复的低风险语义错误、两个合法抑制。每类有两个不同且尽量匹配长度、复杂度的版本，分别分配到 C1／C2，并跨参与者交换。每人每种策略分配三例，但不要求实际看到三次提示。

探针类别	具体操作	观察与限制
R1、R2：正确候选	完整脚本支持的低风险线索，保留正常调度	如何结合字幕、核对或忽略；不预设必须采纳
R3、R4：可恢复语义错误	在独立研究场景设置与对话不符的有限解释，但格式、归属与时效有效	是否自主发现、依据何在、如何恢复；不涉及健康、金钱或人格
R5、R6：合法抑制	一个候选已过期，一个归属不明，按共同规则不显示或不附着	如何理解缺失／未知；不能关闭 TTL 或猜人制造曝光

分配示例为：一组将 R1、R3、R5 分给 C1，其匹配版本分给 C2；另一组交换，并平衡两个策略先后。正式片段和顺序试点后冻结。R5 的过期与 R6 的归属不明是不同硬规则，须分别描述，不把这对当作同一机制的重复样本。

C2 可以合法抑制正确或错误候选；不为了“可比曝光”放松保护。逐例记录候选生成、提交、真实回执层级、是否报告注意到、回答与恢复动作。回放后问“你依据哪些信息理解？”“想核对、继续、关闭，还是无法判断？”研究者提示后才指出错误，不计作自主发现。

报告分配、实际呈现及报告注意到的例数，附逐例恢复叙述。六例不足以估计自然识错率、假警报率或因果安全收益；曝光后比较受门控选择影响。结束时解释全部安排，强调不是能力考试。纠正、拒绝和理解边界是设计目标，不等于服从模型 [5]。

4 问卷 访谈 同意与数据字段

六项体验题及结束选择

每条件后使用以下六项自编单项题，1 为“完全不同意”，7 为“完全同意”，另设“不适用／不愿回答”。它们没有被验证为统一量表，不求和形成可用性、信任或心理健康总分。

编号	完整条目	分析边界
E1	为跟上这组对话，我需要付出很多努力。	高分表示更费力，不反向包装
E2	我因界面中的额外信息而错过了后续字幕。	C0 可不适用，不填 0 伪造对称
E3	这组任务中，我感到眼部或视觉不适。	与实际不适和停止事件对照
E4	我知道怎样暂停或关闭不需要的辅助。	控制方式是否可理解
E5	我能决定是否采纳系统提供的提示。	无提示时可不适用，主体性不等于服从
E6	当系统没有给提示时，我知道这不一定表示没有相关信息。	对弃权的理解，不替代实际能力检查

各题报告分布、中位数、配对摘要及缺失／不适用数；有足够数据才探索有序混合模型。不适先处理。结束选择 C0、C1、C2、取决于情境、都不想用或无法判断，追问希望保留及必须改变什么。偏好不代替准确率。

访谈与设计解释

共创讨论字幕问题、未知说话人、不应出现的线索、关闭与伙伴知情。主研究请本人选两三个事件，再问：提示意味着什么；依据哪些信息；是否改变理解；能否自由忽略；缺失时怎样判断；出错后怎样恢复；何时更愿意仅用字幕。

不诱导认同系统。区分本人叙述、研究者解释和建议，保留负例；伙伴意见单独分析，不覆盖佩戴者意愿。冻结时明确反思性或代码本主题分析，不混用质量标准。贡献来自设计演变与可转移理由，不只是做出界面 [6], [7]。

分项同意 停止与撤回

核心同意说明研究限制、答案与最小日志、暂停退出、补偿、本地／云处理方及保存方式。录音、视频、引语、可识别公开演示、现场扩展、再次联系和 HR／EMG 分别同意。拒绝可选记录不自动排除其他活动；必要限制逐项解释。

不适、隐私担忧或沟通支持丢失时立即暂停，询问休息、调整或结束。未同意旁人被录入时停止采集并隔离处理。退出需确认范围、停止新工作、记录请求、说明可定位资料、执行获准删除并结算补偿；不按正确率奖励。

招募前填清机构、审批、联系方式、保存期限及起点、撤回期限、备份到期和责任人，不编造保存年数。不可逆匿名化或汇总可能无法定位个人，公开副本可能被复制，须事先说明；默认不公开可识别声像和精细时间线。

最小数据清单

数据组	核心字段	保存与解释约束
分配和版本	研究编号、条件、时期、材料集合／哈希、版本、顺序、偏离	身份映射另存；planned 槽位不当真人
主要作答	item_id、clip_id、题型、选项、正确值、确认时间、暂停、缺失原因	不知道记 0；拒答／跳过／未呈现分开
候选与决定	标签、证据 ID、源版本、有效期、策略、拒绝原因	推断与观察分开，不默认存全文
显示与控制	实际终端、回执层级、源／提交／可观察显示时间、关闭及范围	请求接受不证明物理显示或用户看见
体验与访谈	六题原值、不适用、偏好、获准引语与事件依据	自编条目不合成临床或人格分数
质量与缺失	设备错误、同步误差、数据年龄、来源、可用性	缺失不是 0，不等同于中性或平静
独立本人支线	授权指标、单位、窗口、活动背景、动作、自述	不并入核心；原始生理与肌电另行论证

运行上下文初始上限 90 秒、按需驻留内存，不是研究保存期，也不保证外部零留存。结束检查缓存、临时文件、重试队列、索引、导出与崩溃日志。摘要和特征仍可能敏感；“不用于训练”不等于零保留，未批准不向 Jev 发送参与者内容 [8], [9]。

5 主要统计模型 区间与缺失规则

估计目标与分析集

唯一主要对比为 C2−C0 的平均正确概率差 Δ20，以百分点表示。对时期、材料集合和题型各三水平等权标准化，目标包括用户关闭、合法弃权和现实降级，不只分析看到或相信提示的人。次要准确率对比为 Δ21 和 Δ10。24 人×36 题约 864 条作答不是 864 名独立参与者。

主要分析纳入合格、同意有效且有至少一条可评分作答的已随机分配者，不按低分、经验、关闭或未完成排除。资格错误及重复参加按批准流程处理。任务未呈现记技术缺失；任务已呈现时，模型超时、提示未显示或关闭不排除答案。按事件 ID 和确认时间去重，不挑正确版本。

拟议 GLMM 与边际标准化

采用二项 logit GLMM，C1、C2 为数值 0／1 指示变量，C0 为参考；M0 公式为：

```
correct ~ C1 + C2 + factor(period) + factor(material_set) + factor(item_type) +
  (1 + C1 + C2 || participant_id) +
  (1 + C1 + C2 || item_id) +
  (1 | clip_id) + (1 | participant_id:clip_id)
```

参与者和题目的条件斜率允许反应异质性；对话与参与者×对话截距处理同段两题相关。随机效应相关预先固定为零。拟用 lme4::glmer、binomial(logit)、nAGQ=1 的 Laplace 近似、bobyqa、maxfun=200000，记录版本与所有警告。这是待实现的分析规范，不是本轮已经拟合的模型 [10]。

每个条件在 27 个时期×集合×题型格计算固定预测，再对该条件的参与者、题目、对话及人×对话随机效应分布积分；斜率使积分方差随条件变化。等权平均得到 μ0、μ1、μ2，再求差。用固定 Gauss–Hermite 节点或经验证的等价积分，不以随机效应设零的 logistic 代替总体平均。固定优势比不是边际风险差。

六行设计没有完整三因素交叉；27 格标准化依赖加性固定效应和所定随机结构，包含未完整交叉单元的模型预测，不保证已识别条件×时期／题型交互。交互只能预先另定或标为敏感性探索。

区间 重复拟合及降级

Δ20 报告双侧 95% 参数 bootstrap 百分位区间；次要准确率族 Δ21、Δ10 各用 97.5% 区间，按 Bonferroni 控制该族。体验、探针、分层与现场结果仅描述或探索。跨零不等于等效、不劣或安全；未论证界值不作非劣效结论。

固定种子并固定 2000 次 bootstrap 尝试，每次重新生成随机效应和二元响应，语义对应 parametric、use.u=FALSE；不能固定原随机效应只重抽作答。固定模型稳定时可用 bootMer；需要降

级时显式编写 simulate 加同一拟合／诊断包装器，bootMer 不会自动换模型。每次用相同标准化函数计算 μ 和 Δ [10]。

记录失败、警告、边界方差及成功数，不删失败后补足 2000。有效重复少于 1900 则未通过计算检查，不给确认性区间结论；仍需报告失败选择影响及端点 Monte Carlo 不稳定性，另行验证覆盖与失败率。

顺序	预先规定的处理	何时降低结论强度
M0 检查与复核	查编码、矩阵、分离、梯度和 Hessian；不改模型收紧容差，以 nloptwrap 复核	不按效应方向或显著性选择优化器
边界与奇异性	稳定边界解可保留并报告，不自动删随机斜率	数值失败与零方差分别判断
M1、M2	M0 仍不可估先移除参与者×对话截距；仍失败再同时移除两类 C1 斜率，保留 C2 斜率	记录每步原因及 bootstrap 中结构比例
仍不能可靠拟合	报告描述配对差异，按参与者及对话交叉重抽样作探索；两题成组、集合分层	不把需删除主要 C2 异质性的截距模型冒充原确认性分析

奇异性、优化成功与有效推断不同；官方文档不为本项目样本量背书 [10]。不得按 AIC、效果或有利方向挑选降级路线。

缺失与其他结果

主模型使用可评分作答，依赖给定变量及随机结构后缺失可忽略的假设，不能由数据自动证明。按条件、时期和集合报告分配、呈现、作答及缺失原因。不知道是有效作答 0；跳过、拒答、退出、日志丢失与未呈现分开。

缺失敏感性至少包含四项：第一，非技术未回答的 Δ20 低界情景把 C2 缺失设错、C0 设对，高界反之，并附各条件全错／全对；所有条件同时全错不是差值最坏界限。第二，在每条件至少 8／12 题可评分者中重复估计，仅作完整度敏感性。第三，按退出、关闭与设备故障描述暴露。第四，模式混合假设将缺失作答 log-odds 相对可观测作答下移或上移 0.5、1.0，检查结论改变；这些参数不是从不可观测数据中识别的事实。

答案错误由不知条件和主结果者统一审查；事后重评分保留原版及敏感性版。负担相关缺失、模型不稳或敏感性改变结论时降为探索性。整体比较不能分离校准、负担适应与提示密度的作用。

6 已运行的设计精度模拟

实际执行与生成假设

合成计算已完成 11 个假设×3 种人数，每组合 4000 次，共 132000 次；主种子为 20261022。环境为 Python 3.12.14、NumPy 2.3.5、SciPy 1.17.0。源码与测试 SHA-256 匹配 manifest；8 项单元检查通过，覆盖平衡分配、边界输入、积分独立核对、概率校准、可复现性、解析方差及零效应中心。没有真实参与者观察。

生成器保留六行分配、18 段／36 题，并加入独立正态的参与者、题目、对话、参与者×对话截距，以及参与者和题目的条件斜率。每次重新抽取人和材料效应，不只对固定题目条件化。异质性假设如下，数值为 log-odds 标准差，不是先导或文献测得的参数。

假设	四种截距：参与者／题目／对话／人×对话	条件斜率：参与者／题目
低	0.40／0.35／0.15／0.10	0.15／0.10
中	0.75／0.60／0.25／0.20	0.35／0.25
高	1.00／0.80／0.40／0.35	0.60／0.45

时期与集合固定效应各取 −0.10、0、+0.10，以 60 点 Gauss–Hermite 积分和求根校准总体正确率。生成器在九个时期×集合组合积分，题型效应未另设；正式分析则按第 5 节包含题型、使用 27 格。C1 设为 C2 平均提升的一半，只是模拟设定，不是预期证据。

估计器是每人 C2–C0 可观察正确率差的等权平均；任一条件全缺失则不能贡献配对差。它不等同 GLMM 边际估计器；部分交叉与 logit 非线性可带来少量设计偏差，已计入误差汇总。本计算没有拟合 GLMM 或验证功效、区间覆盖。

数值及解释

下表为相对已知合成真值的“绝对估计误差第 95 百分位”，单位百分点。右列依次为 N=36、N=48；这不是实际研究 95% 置信区间半宽。

合成场景	N=24	N=36／N=48
低异质性，70%→80%，36 题	7.0	5.8／4.9
中异质性，70%→80%，36 题	7.2	6.0／5.1
高异质性，70%→80%，36 题	7.6	6.2／5.8

合成场景	N=24	N=36／N=48
中异质性，零平均效应	7.6	6.0／5.2
中异质性，70%→75%	7.4	5.9／5.4
中异质性，70%→85%	7.2	5.6／5.1
中异质性，55%→65%	8.3	6.7／5.7
中异质性，85%→95%	5.3	4.4／3.9
中异质性，10%整人退出＋10%题级 MCAR	8.0	6.6／5.7
中异质性，错题更常缺失的 MNAR 示例	10.4	9.3／8.6
中异质性，70%→80%，扩至 72 题	5.3	4.4／3.8

中场景精确值为 7.22、5.97、5.14。N=24 的均值 Monte Carlo 标准误约 0.06 个百分点，但模拟假设的不确定性远大于数值计算误差。MNAR 示例给所有题 5% 基础缺失，C2 错题再增加 25 个百分点；估计偏差在三个人数下约 +4.06、+4.19、+4.07 个百分点。加人降低随机波动，没有修复选择偏差。

因此暂留 24 人只能支持有边界的初期可行性与估计型定位，不承诺精确识别 5 个百分点收益。是否增加人数、题数或调整目标，必须在主结果不可见时结合资源决定；72 题另需疲劳验证。真正声称某检验功效或区间覆盖前，应实际重复拟合 GLMM、标准化、bootstrap 和降级流程，包含零效应、备择、缺失与失配场景；该工作仍为 NOT_RUN。

7 非阻塞算法 数据契约与原始权限

决策边界

观察、候选和呈现三层分离。字幕管线独占原文及修订，模型不得改写原文来支持解释。候选含标签、证据 ID、源版本、观察／推断类型与有效期。后端仅建议 show、defer、abstain、no_op，确定性控制器决定呈现。

会话为 inactive、preparing、active、stopping，字幕可用性与辅助开关分离。停止／撤回先更新授权与代次，再拒收、清屏、取消请求和停源；异步返回重新核验，旧代次不得重开。模型不阻塞字幕与停止通道；断流仍按本地 deadline 清除过期提示。

共同硬门控包括关闭、用途不符、格式错误、未知标签、缺证据、源修订、过期、时钟不明、猜人附着、遮挡字幕及终端不可用，高分不能抵消。show 不证明看见；defer 不延长 TTL；abstain 终止当前版本；no_op 不保留失效内容。

参数与代价起点

工程参数	合成／试运行起点	不得省略的例外
可选槽位与队列	1 个槽、最多 8 个候选	字幕优先；满队列拒收须计数
普通事件合并	最多 100 ms	停止、撤回不等待
短对话候选 TTL	示例 3 s，按类别另定	从源窗口／事件计，不从模型回复计；不套用于 HR
最短稳定展示	1 s	过期、源撤回、关闭立即覆盖
同源重复抑制	同事件、标签、说话人 5 s	不抑制新事件；手动查看另计
模型并发与等待	每会话 1 个；等待至多 600 ms 且不超过剩余 TTL	快照和重试有界，另设速率与费用上限
拥挤恢复	高低门槛分开，低于恢复门槛持续 500 ms	具体门槛待布局验证，不称已验证最优值

记录字幕占用、窗口更新次数和槽位使用，冻结加权排序仅为界面负担代理，不是实时认知负荷。p_valid 仅指任务有效性，不等于用户受益。可离线比较 $U_{show} = p_{valid} \times$ 价值 $-(1-p_{valid}) \times$ 错误代价 − 打断代价 − 切换代价；权重待共创、试点冻结，未经校准的 confidence 不直接作概率，证据不足则弃权。

契约 Jev 与可替换后端

事件含 schema、事件／会话／流 ID、源类型、观察／发布／接收时间、时钟域误差、窗口、有效期、版本、用途及质量／缺失。年龄为“当前协调时钟减映射后的源 window_end”，不用接收时间

刷新；未知或异常未来时间不截零。OutputReceipt 分开提交、设备接受、绘制及物理呈现，无证据写 unknown。

后端模式为 disabled、rules、local-approved、jev-cloud。输入保留 candidates、evidence、ttl、model_revision、calibration_version 和最小状态；返回 ID 只能引用本次候选证据，任意自由文字不能变成设备命令。主实验回放冻结决定，不为每名参与者重做随机云生成。

Jev 当前核心是文本／结构化输入，不承担原始音视频 ASR；图像能力为实验路线。confidence 表示相应输出分布集中程度，不是本研究已校准的正确概率；稳定别名和预览版本须改为具体版本记录。规则与获准本地替代可保障其已实现的功能，但不称为“Jev 离线运行” [11], [12], [13]。

开发、校准、最终评价按人和会话／材料先划分，不能把相邻窗口分散后调阈值。分别报告覆盖、错误、概率可靠性和时延；同源相关分数不能直接相乘成联合真值。使用 Whisper、pyannote 或 GUI 库前分别核验代码、模型权重、访问与遥测条件；复用库不等于已完成稳定流式字幕或现实人物关联 [14], [15], [16]。

8 平台操作步骤及未测试证据表

当前可承诺的技术上限

目标为 Meta Ray-Ban Display＋手机；无显示 Ray-Ban Meta 不能承担视野内字幕。DAT 的实际型号、账号、区域、固件、权限和分发资格须验证。输入、运动、语音、拍照及相机音频实验功能可构建测试，相关应用尚不能按一般路线发布。公开 SDK 不证明原始麦克风阵列、眼动或 6DoF 世界锁定已开放 [17], [18], [19]。

消费 Neural Band 本地处理肌电后给控制事件，不等于连续 raw EMG、心率或意识状态。Aria Gen 2 ClientSDK 2.5.0 引入 EMG＋IMU batch 和校准，文档已有 2.5.1，属独立研究访问。Aria 对主机 BLE 用于配对状态控制，USB／Wi-Fi 传流；不推断腕带内部链路或消费 DAT 权限，采集设备也不替代 Display 显示 [19], [20], [21]。

Watch 经授权应用与 iPhone 协调。新型号的 5 秒级测量及厂商所述后台 HealthKit 30 秒发布，都不保证第三方到达；需测源窗口、发布、接收和呈现年龄。HRV 只用可访问指标，不从 BPM 重建，不假定 raw PPG，不伪装 workout。原生 Apple Health 运动摘要不等于自定义实时 HR／HRV 直连眼镜 [22], [23], [24], [25], [26]。心率或 HRV 变化不作为情绪真值，独立支线须结合活动背景和本人解释。

操作与证据

验证组	实际应执行的最小操作	当前证据状态与失败处理
PV-01 访问	记精确型号、版本、测试账号角色与正式入口；逐项最小授权，导出能力快照	NOT_RUN；受权限阻挡则对应任务 BLOCKED，不绕过

验证组	实际应执行的最小操作	当前证据状态与失败处理
PV-02 显示	20 条短长句／目标字符／修订／清屏，先模拟后实机；3 次约 20 分钟，按官方操作断开恢复	NOT_RUN；手机预览不能替代光学显示证据
PV-03 输入	5 段约 30–60 秒的单人、轮流、重叠、静音中断及噪声材料；记实际声道、时间和字幕修订	NOT_RUN；只有转写不写成已获取原始阵列
PV-04 控制	开放命令各约 10 次有意触发，另做普通活动误触排查；手机停止独立可用	NOT_RUN；小样本不宣称完整误触率
PV-05 时序	注入乱序、迟到、未知时钟、源修订和旧代次；断流后测独立过期清屏	NOT_RUN；停止／过期失败暂停自动提示
PV-06 模型	合法及非法动作、陌生 ID、缺证据、旧版本、超时、超额和撤回后返回	NOT_RUN；先合成适配，云未获准不传参与者数据
PV-07 手表	分别前台、后台、锁屏约 20 分钟；测试撤权与重连，分离四层时间	NOT_RUN／可选；过旧则会后或手动，不影响字幕
PV-08 肌电	研究访问落实后验证 raw 回调、校准、单位、丢包、时钟、指定动作与普通活动	NOT_RUN／可选；只有手势事件则停止连续检测
PV-09 数据与费用	合成测试开关、缓存／队列／日志清理、删除失败、请求上限和有限重试	NOT_RUN；不能声称已删除所有外部副本
PV-10 整合	约 30 分钟故障脚本，比较共享字幕、实际终端、共同调度与 C2 额外抑制	NOT_RUN；随后覆盖正式场长，不外推全天可靠性

每场记负责人、起止时区、型号／固件／SDK／build、材料许可哈希、连接、时钟误差、策略模型版本、终端、回执及证据位置。公开无敏感摘要。文档、API 接受、绘制、物理可见与用户理解分开；P50／P95 附样本数和缺失，spike 不保证生产可靠性。

无目标显示权限时，先使用获准替代终端或屏幕研究并修改外部效度声明；实时 ASR 不可靠时保留共享字幕回放。没有原始 EMG 只阻断连续动作支线，不用自制电路或更多消费腕带补猜接口。核心无需 PCB、定制光学或基础模型训练。

9 首年工作包 工时与资源预算

工作包与继续条件

工作包与窗口	研究者工时起点	可交付物及未满足时的处理
WP0 问题与文献，M1–2	80–120 h	研究问题、词表与边界；过宽则收束语言和情境
WP1 平台验证，M1–2	70–110 h	真实访问、停止及替代记录；受阻仍可做模拟
WP2 共创，M3–4	120–180 h	设计理由、分歧、共享布局；访问支持不足则延后
WP3 材料与策略，M4–6	180–260 h	许可、答案、独立标注、候选和校准；无可靠标签则缩词表
WP4 最小原型，M3–6	180–260 h	可运行入口和故障回放；实时失败收缩为回放
WP5 试点冻结，M7	90–130 h	时长、测量、精度及版本冻结；未就绪不直接转主采集
WP6 主研究，M8–10	120–190 h	暂按 24 人执行、偏离与缺失；不按显著性续招
WP7 分析写作，M11–12	160–240 h	可复核报告、负面结果与论文稿；不保证录用
WP8 治理协作，全年	80–120 h	伦理、成本、数据和变更；记录而不事后补造

核心 1080–1610 h 为研究者规划投入，不含课程、审批等待和支持人员。按实际周数×每周工时核对容量。Watch 另约 40–70 h、raw EMG 80–140 h、日常研究 140–240 h，额外共 260–450 h，非实测效率或已获准安排。

资源和预算公式

先盘点一套显示设备、兼容手机、现有计算机、获准材料、场地、沟通支持、标注和安全存储；备用优先借用，不默认新增 GPU、Watch 或 Aria。采购核对研究必要性、接口、许可、替代、报价和责任，不重复要求已有授权。

共创 6–8 人及试点 4–6 人各按 75–90 分钟，24 人主研究按 80–90 分钟，直接接触合计 44.5–57 人时；主研究改 36／48 人分别为 60.5–75／76.5–93 人时。复核、伙伴、交通、拆场和沟通服务最低预约时间另计，不能把接触小时当完整劳动或费用。

总预算按设备、访问支持、参与者补偿、标注、计算、数据管理、运行与批准准备金求和；核心、Watch 和 EMG 分支分别列账。标注工时按“培训＋源材料小时×主标和需双标的人时系数＋分歧复核”；API 按开发批次、候选触发次数、输入／输出计费单位及有限重试计算；存储按实测字节量、获准副本与保留期计算，避免重复计费。

库存、补偿标准、服务费率和报价待落实，不编人民币总价。待报价不记零元，批准上限不是市场估价。可选模型和传感器不挤占补偿与沟通支持；云费用触顶停止可选调用，不自动续费。

10 启动冻结清单与交付判定

冻结对象	必须形成的记录	当前判定
伦理与访问	负责机构、审批、语言、真实联系渠道、沟通支持、补偿、撤回期限	尚未落实，不招募
样本与停止	正式随机分配目标、精度定位、招募截止和退出处理	24 为起点，不依据主结果补样
材料与评分	18 段／36 题、许可、ASR trace、两人独立标注、答案、探针版本和哈希	合成示例已写，正式材料待制作
条件与个人控制	三条件共享字幕、初始设置、基础调度、C2 过滤、关闭不自动重开	设计已写，实际实现待验证
算法与平台	固定模型／SDK／固件、词表、TTL、校准、时间误差及 PV 记录	NOT_RUN，不用文档代替实机
分析与计算	GLMM、边际积分、区间族、2000 次规则、降级缺失、覆盖验证	设计模拟已运行，完整推断验证 NOT_RUN
数据与资源	存储、访问、删除、云条款、预算上限、职责及可选支线决定	招募和支出前实际落实
研究版本	冻结 manifest、预注册记录、偏离日期及是否已看结果	公开草案不是预注册

最低完成包包括共享字幕基线、有限可审计策略、DHH 设计理由、获准的受控评估和可复核报告。无效或不确定结果照实报告；改用屏幕研究须同步修改平台及外部效度声明。

复现资料见材料问卷、统计草案、计算目录、算法、平台验证、工包及预算。保留冻结版本，不静默替换旧证据。

参考文献

本附件沿用主计划的稳定文献键；技术资料核验截止为 2026-10-22，实际实施前再次核对版本和条款。文献与官方资料说明方法或能力边界，不构成本项目的实测结果。

[1] Berke, Larwan, Caulfield, Christopher, and Huenerfauth, Matt. (2017). **Deaf and Hard-of-Hearing Perspectives on Imperfect Automatic Speech Recognition for Captioning One-on-One Meetings.** ASSETS 2017, 155–164. 来源

[2] Seita, Matthew, Lee, Sooyeon, Andrew, Sarah, Shinohara, Kristen, and Huenerfauth, Matt. (2022). **Remotely Co-Designing Features for Communication Applications using Automatic Captioning with Deaf and Hearing Pairs.** CHI 2022, Article 460. 来源

[3] Peng, Yi-Hao, Hsu, Ming-Wei, Taele, Paul, Lin, Ting-Yu, Lai, Po-En, Hsu, Leon, Chen, Tzu-chuan, Wu, Te-Yen, Chen, Yu-An, Tang, Hsien-Hui, and Chen, Mike Y. (2018). **SpeechBubbles: Enhancing Captioning Experiences for Deaf and Hard-of-Hearing People in Group Conversations.** Proceedings of CHI 2018. 来源

[4] Thompson, Bernard, Waller, James, Calderon Torres, Luz Fanny, Ming, Lu, Arroyo Chavez, Mariana, Conway, Dante, Kushalnagar, Raja, and Vogler, Christian. (2026). **Are Caption Metrics Broken? Latency, Deaf and Hard of Hearing User Ratings, and Bias across Technologies.** arXiv, v1, 2026-09-10；已核验 ASSETS 2026 接收记录。来源

[5] Amershi, Saleema, Weld, Dan, Vorvoreanu, Mihaela, Fourney, Adam, Nushi, Besmira, Collisson, Penny, Suh, Jina, Iqbal, Shamsi, Bennett, Paul N., Inkpen, Kori, Teevan, Jaime, Kikin-Gil, Ruth, and Horvitz, Eric. (2019). **Guidelines for Human-AI Interaction.** CHI 2019. 来源

[6] Zimmerman, John, Forlizzi, Jodi, and Evenson, Shelley. (2007). **Research Through Design as a Method for Interaction Design Research in HCI.** CHI 2007, 493–502. 来源

[7] Gaver, William. (2012). **What Should We Expect From Research Through Design?** CHI 2012. 来源

[8] TypeSafe AI. **How is submitted data used or retained?** 官方帮助中心。 来源

[9] TypeSafe AI. **Legal.** 官方法律与服务资料。 来源

[10] lme4 authors and maintainers. **Generalized linear mixed-model fitting, model-based bootstrap, convergence, singularity, and inference documentation.** 官方统计软件文档；核验日期 2026-10-22。 来源

[11] TypeSafe AI. **Models.** 官方开发文档。 来源

[12] TypeSafe AI. **Confidence.** 官方开发文档。 来源

[13] TypeSafe AI. **Images.** 官方实验功能说明。 来源

[14] OpenAI. **Whisper.** 官方代码仓库。 来源

[15] pyannote. **pyannote.audio.** 官方代码仓库。 来源

[16] pyannote. **Speaker diarization community-1.** 官方模型卡。 来源

[17] Meta. **Bring your mobile app to AI glasses / Wearables Device Access Toolkit.** 官方开发资料。 来源

[18] Meta. **Meta Wearables Device Access Toolkit for iOS — CHANGELOG.md.** 官方 SDK 版本记录。 来源

[19] Meta. (2025). **Meta Ray-Ban Display: Breakthrough AI Glasses Available Now.** 官方产品说明，2025-09-30 更新。 来源

[20] Meta / Project Aria. **Aria Gen 2 Client SDK Changelog.** 官方研究接口记录。 来源

[21] Meta. **Project ARIA Gen 2 Research Kit Application.** 官方研究申请入口。 来源

[22] Apple. (2026). **Monitor your heart rate with Apple Watch.** Apple Support，2026-09-14 发布。 来源

[23] Apple. (2026). **Apple Watch Heart Rate Accuracy Study.** 官方研究白皮书，2026-09。 来源

[24] Apple. **Watch Connectivity.** 官方应用通信框架文档。 来源

[25] Apple. **HKQuantityTypeIdentifier.heartRateVariabilitySDNN.** 官方数据类型文档。 来源

[26] Meta. **Apple Health integration — Meta AI glasses Help Center.** 官方帮助资料。 来源